Titulación: Grado en Ingeniería Informática, Ingeniería en Sistemas de Información e InfoAde
Curso: 2025-2026. Convocatoria Ordinaria de Mayo
Asignatura: Bases de Datos Avanzadas – Laboratorio

Practica 1: Arquitectura PostgreSQL y almacenamiento físico

ALUMNO 1:

Nombre y Apellidos: Jorge Lopez Duque

DNI: 70943373B

ALUMNO 2:

Nombre y Apellidos: José Antonio López González

DNI: 03209889D

Fecha: _____

Profesor Responsable: Javier Arrollo Gallardo

Mediante la entrega de este fichero los alumnos aseguran que cumplen con la normativa de autoría de trabajos de la Universidad de Alcalá, y declaran éste como un trabajo original y propio.

En caso de ser detectada copia, se calificará la asignatura como Suspensa – Cero.

Es obligatorio proporcionar una explicación a lo que está ocurriendo en PostgreSQL cuando así se indica en la cuestión. No solo vale poner un pantallazo. La ausencia de una explicación hará que sea invalidada esa cuestión.

[redacted]

Introducción

En esta primera práctica se introduce el sistema gestor de bases de datos PostgreSQL (18.1 la última). Está compuesto básicamente de un motor servidor y de una serie de clientes que acceden al servidor y de otras herramientas externas. En esta primera práctica se entrará a fondo en la arquitectura de PostgreSQL, sobre todo en el almacenamiento físico de los datos y del acceso a los mismos. Antes de comenzar es obligatorio configurar lo que se comenta en la cuestión. Hay que resolver la práctica con consultas SQL.

Cuestión 0. Configurar el fichero de Error Reporting and Logging de PostgreSQL para que aparezcan recogidas las sentencias SQL DDL (Lenguaje de Definición de Datos) + DML (Lenguaje de Manipulación de Datos) generadas en dicho fichero. No se pide activar todas las sentencias. No activar la duración de la consulta. También se debe de configurar el log para que en el comienzo de la línea de registro de la información del log ("line prefix") aparezcan vuestros DNI's. ¿Cómo se ha realizado la configuración?

Organización de Archivos en PostgreSQL

Cuestión 1. Crear una nueva Base de Datos que se llame **PL1**. Después crear una tabla **estudiantes** con los siguientes campos:

- estudiante_id: que debe ser un serial empezando por 1.
- nombre: guarda el nombre del estudiante.
- codigo_carrera: guarda el código de carrera del alumno.
- edad: guarda la edad del estudiante.
- indice: guarda el número de créditos superados por el alumno.

Crear un programa que permita generar 30 millones de registros en un fichero de texto que pueda ser cargado posteriormente en la tabla (preferiblemente en Python) con las siguientes propiedades para los siguientes campos, cuyos valores se deben generar aleatoriamente.

- Código de carrera: deben ser valores aleatorios entre 0 y 100.
- edad: deben ser valores aleatorios entre 18 y 40 años (incluidos).
- índice: deben ser valores aleatorios entre 0 y 10000

Cargar los datos en la tabla y localizar los ficheros relacionados con la tabla. ¿cómo se localizan? ¿Cuánto ocupan? ¿por qué?

Postgre almacena las tablas como ficheros heap en el directorio: base/<OID_BD>/<OID_TABLA>.
El tamaño es elevado debido al overhead por fila, el uso de tipos variables como TEXT, los índices creados automáticamente por la clave primaria y los archivos auxiliares FSM y VM necesarios para la gestión interna.

Resultado obtenido:
-Solo tabla: 1.641 MB
-Tabla + índices: 2.284 MB
Por tanto, los índices y estructuras auxiliares ocupan aproximadamente: 2.284 – 1.641 = 643 MB

Los ficheros asociados a una tabla en postgre se localizan a partir de los OIDs de la base de datos y la tabla, dentro del directorio data_directory.
El tamaño total incluye no solo los datos de la tabla, sino también los índices y estructuras auxiliares necesarias para la gestión interna del sistema gestor, lo que explica que ocupe tanto espacio.

Cuestión 2. Calcular teóricamente el tamaño en bloques que ocupa la relación **estudiantes** tal y como se realiza en clase de teoría. ¿Concuerda con el tamaño en bloques que nos proporciona PostgreSQL? ¿Cuál es el factor de bloque medio real de la tabla **estudiantes**? ¿Por qué? Realizar una consulta SQL que obtenga ese valor y comparar con el factor de bloque teórico.

estudiante_id SERIAL -> INTEGER (4 bytes)
nombre TEXT -> suponemos 10 caracteres -> aprox 10 bytes, codigo_carrera INTEGER -> 4 bytes
edad INTEGER → 4 bytes, indice INTEGER → 4 bytes
-Suma total: 4 + 10 + 4 + 4 + 4 = 26 bytes
Postgre usa por defecto: 8 KB = 8.192 bytes por bloque
bfr = 8.192/26 = 315 reg/bloque
Numero teorico de bloques: 30.000.000/315 = 95.238 bloques.

-Tamaño real:

-Consulta SQL usada:

```
SELECT
  reltuples::bigint AS filas_estimadas,
  relpages AS bloques,
  (reltuples / relpages) AS factor_bloque_medio
FROM pg_class
WHERE relname = 'estudiantes';

relpages = número de bloques
reltuples = número estimado de filas
```

relpages = 210.000 bloques (que viene a ser mas del doble de los teoricos)
Por lo que bfr(real) = 30.000.000/210.000 = 143 reg/bloque.

El tamaño en bloques calculado teóricamente no coincide con el tamaño real proporcionado por postgre, debido a que el modelo teórico no considera el overhead interno por registro, la cabecera de bloque, la alineación de datos y la gestión interna del sistema gestor. El factor de bloqueo medio real es significativamente menor que el teórico.

Cuestión 3. Realizar una consulta que muestre los estudiantes que tengan un índice de 500. ¿Cuántas tuplas se obtienen y cuántos bloques se leen del disco por Postgres? ¿Por qué? Obtener las estadísticas de la tabla y sus campos, para comparar con los resultados obtenidos al aplicar el método visto en teoría. (usar funciones de "The Cumulative Statistics System")

La consulta realiza un escaneo secuencial de la tabla, ya que no existe índice sobre el atributo indice. Postgre debe leer todos los bloques del fichero heap, por lo que el número de bloques leídos coincide aproximadamente con el número total de páginas de la relación.
El número de tuplas obtenidas se aproxima al valor teórico esperado según la distribución uniforme del atributo (aprox 3.000 tuplas).

Las estadísticas obtenidas mediante pg_stat_user_tables y pg_stats permiten comprobar la cardinalidad y la selectividad del atributo, confirmando el comportamiento observado.

PONER AQUI LO DE SHARED HIT Y SHARED READ PARA COMPARAR CON LO DE TEORIA DECIR QUE COINCIDE CON LO DE LA LECTURA SECUENCIAL (al no estar ordenado por el parametro indice habra que mirar todos los registrso, es decir, acceder a todos los bloques).

Cuestión 4. Volver a realizar la consulta de la cuestión 3 de nuevo. ¿Cuántas tuplas se obtienen y cuántos bloques se leen del disco por Postgres ahora? ¿Por qué? Comparar con la cuestión anterior

Aunque la consulta se ejecuta por segunda vez, postgre sigue realizando un escaneo secuencial completo. Debido a que la tabla es mayor que la memoria compartida disponible, la mayoría de los bloques deben volver a leerse desde disco. Solo una pequeña parte de los bloques permanece en la caché, lo que explica lao datos que muestran shared hit y shared read.

PONER AQUI OTRA VEZ LO DE SHARED HIT Y SHARED READ PARA COMPARAR CON LOS DE ANTES.

Cuestión 5. Crear una tabla **estudiantes2** cuyas tuplas estén ordenadas físicamente por el campo índice de menor a mayor y que tenga la misma información. Cargar el mismo fichero de datos creado en la cuestión1. Indicar el proceso de generación de dicha tabla ordenada. ¿Cuántos bloques ocupa la tabla ahora? ¿Hay algún cambio? ¿Por qué?

La tabla estudiantes2 se genera utilizando:

```
CREATE TABLE estudiantes2 AS
SELECT *
FROM estudiantes
ORDER BY indice;
```

lo que provoca que las tuplas se escriban físicamente ordenadas por el atributo indice.
El número de bloques ocupados es similar al de la tabla original, ya que el tamaño de los registros no cambia.

PONER EL NUMERO REAL DE BLOQUES QUE OCUPA

La ordenación mejora la localidad de acceso pero no reduce significativamente el espacio ocupado.

Cuestión 6. Repetir la cuestión 3 sobre la tabla **estudiantes2** y comparar los resultados obtenidos indicando las conclusiones obtenidas. Relacionarlo con lo visto en teoría.

Aunque la tabla estudiantes2 esté físicamente ordenada por el atributo indice, postgre realiza un escaneo secuencial completo al no existir un índice sobre dicho atributo.
Por ello, el número de bloques leídos es prácticamente el mismo que en la tabla desordenada. Esto se debe a que postgre no utiliza búsqueda binaria sobre el heap, por lo que el orden físico solo mejora la localidad de acceso, lo cual ha sido visible a la hora de ejecutar la sentencia pues ha tardado una menor cantidad de tiempo que antes, pero no reduce el coste del escaneo secuencial.

PONER VALORES DE READ Y HIT

Cuestión 7. Borrar 5000000 tuplas de la tabla **estudiantes** de manera aleatoria usando el valor del campo estudiante_id. ¿Qué es lo que ocurre físicamente en la base de datos? ¿Se observa algún cambio en el tamaño de la tabla y estructuras asociadas a ella? ¿Por qué? Adjuntar el código de borrado.

Al eliminar 5.000.000 de tuplas de forma aleatoria, postgre marca las filas como muertas debido a MVCC. El espacio físico de la tabla y los índices no disminuye inmediatamente, aunque las tuplas ya no sean visibles. El factor de bloque real se reduce y se genera fragmentación interna.
Solo un VACUUM FULL recupera el espacio en disco y compacta la tabla.

NO SE SI SE USARA ESTO, CAMBIAR SI SE HA REEMPLAZADO EL CODIGO POR LO DE TABLESAMPLE:

Usar ORDER BY random() garantiza aleatoriedad perfecta pero es muy costoso en tablas grandes; métodos alternativos permiten eliminar filas de forma rápida aunque la aleatoriedad sea aproximada.

ADJUNTAR CODIGO DE BORRADO AQUI (aun no pongo nada por si se cambia)

Cuestión 8. Insertar un nuevo estudiante en la tabla **estudiantes**. ¿dónde se inserta físicamente la nueva tupla? ¿Por qué? (Mirar apartado “System Columns”)

Cuando insertamos un nuevo estudiante, postgre lo coloca físicamente en el primer bloque con espacio disponible en el heap.
La ubicación exacta se indica mediante la columna del sistema ctid que identifica el bloque y la posición dentro de ese bloque. Si no hay espacio libre, se asigna un nuevo bloque.
Esto permite reutilizar espacio de filas eliminadas y mantener eficiencia de almacenamiento.

Cuestión 9. En la situación anterior, ¿Qué operaciones se pueden aplicar a la base de datos **PL1** para optimizar el rendimiento de esta? Aplicarlas de tal manera que se recupere el mayor espacio posible. Comentar cuál es el resultado final y qué es lo que ocurre físicamente. (Mirar "Routine Database Maintenance Tasks")

Tras la eliminación masiva de tuplas, la tabla presenta fragmentación interna y múltiples tuplas muertas debido al mecanismo MVCC de postgre.
Para optimizar el rendimiento se pueden aplicar operaciones de mantenimiento como VACUUM, ANALYZE, REINDEX y especialmente VACUUM FULL.
Mientras que VACUUM solo permite reutilizar espacio internamente, VACUUM FULL reescribe completamente la tabla eliminando definitivamente las tuplas muertas, compactando las páginas y reduciendo el tamaño físico en disco. Como resultado final, el número de bloques disminuye, el tamaño en disco se reduce y el factor de ocupación real mejora significativamente.

METER LOS VALORES QUE NOS DA.

Cuestión 10. Crear una nueva tabla denominada **estudiantes3** con los mismos campos que la cuestión 1 y que esté particionada por el campo código de carrera por medio de la función h = código_carrera mod 20. Insertar los datos del fichero de datos generado en la cuestión 1. Explicar el proceso seguido y comentar qué es lo que ha ocurrido físicamente en la base de datos. ¿Cuándo será útil el particionamiento? ¿Cuántos bloques ocupa cada una de las particiones? ¿Por qué? Comparar con el número bloques que se obtendría teóricamente utilizando el procedimiento visto en teoría. (Ver comando "CREATE TABLE")

Se crea la tabla estudiantes3 particionada por hash sobre el campo codigo_carrera con módulo 20. Postgre distribuye automáticamente cada fila en una de las 20 particiones físicas según el valor de codigo_carrera mod 20.

Físicamente se generan 20 tablas independientes, cada una con su propio heap y bloques.

Dado que los valores están distribuidos uniformemente, cada partición contiene aproximadamente 1.500.000 filas y ocupa alrededor de 1/20 del número total de bloques originales (10.500 aprox).

El particionamiento es especialmente útil cuando las consultas filtran por el campo de partición, ya que permite reducir el número de bloques leídos mediante partition pruning.

CALCULOS DE TEORIA Y COMPARAR CON LOS REALES

Cuestión 11. Repetir la cuestión 3 sobre la tabla **estudiantes3** y comparar los resultados obtenidos con lo visto anteriormente en las tablas **estudiantes** y **estudiantes2** obteniendo conclusiones sobre el método de partición.

Al repetir la consulta sobre la tabla estudiantes3, postgre realiza un escaneo secuencial sobre cada una de las 20 particiones, ya que el filtro se aplica sobre el atributo indice y no sobre el campo de partición codigo_carrera.
Por tanto, no se produce partition pruning y el número total de bloques leídos es similar al de la tabla original sin particionar.

El particionamiento por hash es útil solamente cuando las consultas filtran por el atributo de partición, ya que permite reducir el número de particiones accedidas y, por tanto, el número de bloques leídos. En este caso, no se obtiene mejora de rendimiento.

PONER LOS VALORES DE SHARED HIT Y READ PARA COMPARARLOS MAS DIRECTAMENTE.

Indexación de PostgreSQL

PostgreSQL soporta indexación definida por el usuario para ayudar a acelerar ciertas consultas. Entre otros tipos de índices soporta árboles y hash. En este apartado se va a trabajar sobre ambos tipos de índices, pudiendo observar cómo se organizan internamente y su funcionamiento. (Mirar módulos "pgstatuple" y "pageinspect")

Cuestión 12. Borrar todas las tablas **estudiantes, estudiantes2** y **estudiantes3**. Crear una nueva tabla que se llama **estudiantes2** como en la cuestión 5 (prdenado por el campo **índice**) y que tenga cargados todos los datos del fichero de texto generado.

HA SIDO UN BORRADO Y UNA CREACION NO MUY EXTRAÑA, NO SE QUE PONER EXACTAMENTE

Cuestión 13. Crear un índice de tipo árbol para **estudiante_id**. ¿Dónde se almacena físicamente ese índice? ¿Qué tamaño tiene? ¿Cuántos bloques tiene? ¿Cuántos niveles tiene? ¿Cuántos bloques tiene por nivel? ¿Cuántas tuplas tiene un bloque de cada nivel? Indicar el procedimiento seguido e incluir el código SQL utilizado.

El índice arbol B se almacena físicamente como un archivo independiente dentro del directorio de datos de postgre.
Está estructurado en páginas de 8KB organizadas jerárquicamente en niveles (raíz, internos y hojas).
Las páginas hoja contienen las claves indexadas y punteros a las tuplas del heap.
El número de niveles se obtiene mediante la función bt_metap, mientras que el número de bloques y su ocupación se obtiene con pg_relation_size y funciones del módulo pageinspect.

PONER LOS VALORES DE LAS COSAS QUE NOS PIDE

Cuestión 14. Determinar el tamaño de bloques y el número de niveles que teóricamente tendría de acuerdo con lo visto en teoría. Comparar los resultados obtenidos teóricamente con los resultados obtenidos en la cuestión 13.

HACER TODOS LOS CALCULOS

Cuestión 15. Crear un índice de tipo hash para el campo **estudiante_id**. ¿Dónde se almacena físicamente ese índice? ¿Qué tamaño tiene? ¿Cuántos bloques tiene? ¿Cuántos cajones tiene? ¿Cuántas tuplas tiene de media un cajón? Indicar el procedimiento seguido e incluir el código SQL utilizado.

tuplas por cajon = 30.000.000/num_buckets

El índice hash se almacena físicamente como un archivo independiente dentro del directorio de la base de datos. Está organizado en cajones en lugar de niveles jerárquicos. El número de cajones se obtiene mediante la función hash_metapage_info. El número medio de tuplas por cajones se calcula dividiendo el número total de registros entre el número de cajones A diferencia del arbol B no soporta búsquedas por rango y no tiene estructura en niveles.

Cuestión 16. Determinar el tamaño de bloques y el número de cajones que teóricamente tendría de acuerdo con lo visto en teoría. Comparar los resultados obtenidos teóricamente con los resultados obtenidos en la cuestión 15.

HACER TODOS LOS CALCULOS

ESTO DE ABAJO ES MAS UNA GUIA DE QUE DECIR:
Teóricamente el índice hash requeriría aproximadamente 60.000–75.000 bloques, con un número de cajones ajustado al factor de carga teórico (~0.8). Sin embargo, en postgre el número real de cajones es una potencia de 2 y el sistema utiliza hashing dinámico extensible, lo que provoca diferencias respecto al modelo teórico. Además, la existencia de páginas overflow y el overhead interno hacen que el tamaño real sea superior al calculado idealmente.

Cuestión 17. Crear un índice de tipo árbol para el campo **índice**. ¿Dónde se almacena físicamente ese índice? ¿Qué tamaño tiene? ¿Cuántos bloques tiene? ¿Cuántos niveles tiene? ¿Cuántos bloques tiene por nivel? ¿Cuántas tuplas tiene un bloque de cada nivel? Indicar el procedimiento seguido e incluir el código SQL utilizado.

El índice arbol B sobre el campo indice se almacena físicamente como un archivo independiente dentro del directorio de datos de postgre.
Está organizado jerárquicamente en páginas de 8KB divididas en raíz, páginas internas y hojas.
El número de niveles se obtiene mediante la función bt_metap, mientras que el número de bloques y su distribución por nivel se obtiene mediante funciones del módulo pageinspect.
Las páginas hoja contienen las claves indexadas y los punteros a las tuplas del heap.

Dado que la tabla estaba previamente ordenada por el campo indice, el índice presenta una buena correlación física con la tabla.

Cuestión 18. Determinar el tamaño de bloques y número de niveles que teóricamente tendría de acuerdo con lo visto en teoría. Comparar los resultados obtenidos teóricamente con los resultados obtenidos en la cuestión 17.

HACER TODOS LOS CALCULOS

Cuestión 19. Crear un índice de tipo hash para el campo **índice**. ¿Dónde se almacena físicamente ese índice? ¿Qué tamaño tiene? ¿Cuántos bloques tiene? ¿Cuántos cajones tiene? ¿Cuántas tuplas tiene de media un cajón? Indicar el procedimiento seguido e incluir el código SQL utilizado.

El índice hash sobre el campo indice se almacena físicamente como un archivo independiente dentro del directorio de datos de postgre.
Está organizado en cajones en lugar de niveles jerárquicos.
El número de cajones se obtiene mediante la función hash_metapage_info, mientras que el tamaño y número de bloques se calculan mediante pg_relation_size.

La media de tuplas por cajón se obtiene dividiendo el número total de registros entre el número de cajones.

Debido a la repetición de valores en el campo indice, pueden existir colisiones y páginas overflow.

HACER TAMBIEN LO DE TUPLAS POR CAJON Y ESO.

Cuestión 20. Determinar el tamaño de bloques y número de cajones que teóricamente tendría de acuerdo con lo visto en teoría. Comparar los resultados obtenidos teóricamente con los resultados obtenidos en la cuestión 17.

HACER TODOS LOS CALCULOS

ESTO DE ABAJO ES MAS UNA GUIA DE QUE DECIR:
Teóricamente, el índice hash sobre el campo indice requeriría aproximadamente 60.000–75.000 bloques, con un número de cajones ajustado al factor de carga teórico (~0.8). Sin embargo, en postgre el número real de cajones es una potencia de 2 y el sistema utiliza hashing dinámico extensible, lo que provoca diferencias respecto al modelo teórico. Además, debido a la repetición de valores en el campo indice, pueden producirse más colisiones y páginas overflow, aumentando el tamaño real respecto al cálculo ideal.

Cuestión 21. ¿Qué conclusiones se puede obtener de la gestión y organización de PostgreSQL sobre los dos índices árbol y hash que se han creado y han sido analizados? ¿Por qué? Comparar con lo visto en teoría.

USAR LOS DATOS OBTENIDOS PARA ARGUMENTAR.

La práctica confirma que el índice arbol B es el más eficiente y versátil en postgre, manteniendo una altura reducida y buen rendimiento incluso con grandes volúmenes de datos.
El índice hash, aunque eficiente para búsquedas de igualdad, presenta limitaciones importantes y depende de la distribución de los datos.

Los resultados experimentales concuerdan con la teoría, aunque el sistema real introduce consideraciones adicionales como fillfactor, alineación y gestión dinámica de buckets.

Monitorización de la actividad de la base de datos

En este último apartado se mostrará el acceso a los datos con una serie de consultas sobre la tabla original. En este apartado se pretende mostrar cómo es el acceso a los datos para diferentes tipos de consultas.

PostgreSQL suministra varias vistas estadísticas que se pueden usar para monitorizar los bloques leídos (tipo statio de la sección The Cumulative Statistics System) de cada una de las estructuras creadas en la base de datos. En este apartado se deben usar esas vistas y está prohibido el uso de otro comando para este fin (Table 28.2).

Para ello, borrar todas las tablas creadas y volver a crear la tabla **estudiantes** como en la cuestión 1. Cargar los datos que se encuentran originalmente en el fichero generado en la cuestión 1.

Cuestión 22. Crear un índice primario tipo árbol sobre el campo **índice**, y otro sobre **código_carrera**. También crear un índice hash sobre el campo **estudiante_id** y otro sobre **índice**. ¿Cuál ha sido el proceso seguido para crear cada tipo de índice? Incluir el código SQL utilizado para ello.

```
CREATE INDEX nombre ON tabla USING hash/btree(campoTabla);

Este es un comando ejemplo (si no no me da el espacio), la idea es que Postgre va recorriendo la tabla
fijandose en el campo que le hemos pasado en campoTabla y ya si estamos hablando de un hash, lo mete en
el bucket correspondiente. Si hablamos de un arbol lo que hace es ir construyendolo y metiendo entrada
por entrada donde corresponde. (Al final si entra)

CREATE INDEX arbolIndice ON estudiantes USING btree(indice);
CREATE INDEX arbolCodigoCarrera ON estudiantes USING btree(codigo_carrera);
CREATE INDEX hashId ON estudiantes USING hash(estudiante_id);
CREATE INDEX hashIndice ON estudiantes USING hash(indice);
```

Cuestión 23. Para cada una de las consultas que se muestran a continuación, ¿Qué información se puede obtener de los datos monitorizados por la base de datos al realizar la consulta? Comentar cómo se ha realizado la resolución de la consulta. ¿Cuántas tuplas se han obtenido? ¿Cuántos bloques se han leído de cada estructura? ¿Por qué? Comparar con lo visto en teoría. Importante, reinicializar los datos recolectados de la actividad de la base de datos antes de lanzar cada consulta. Se recuerda que solo se pueden usar vistas sobre las estadísticas de la base de datos (usar funciones de "The Cumulative Statistics System").

1. Mostrar la información de las tuplas con código de carrera igual 50.

En esta consulta hemos encontrado todos los elementos con codigo de carrera igual a 50, la consulta ha hallado 297.000 tuplas y segun las estadisticas se han leido 253 bloques de indice y 258 de tabla; ambos siendo hits de caché.

La consulta la hemos realizado primero reiniciando las estadisticas para ver bien que está pasando, segundo con esta sentencia SQL: `SELECT * FROM estudiantes WHERE codigo_carrera = 50;` y tercero consultando en pg_stat_all_tables y pg_statio_all_tables.

Los datos sugieren que se leyó el arbol y de ahí se mando con los punteros a la tabla. Por eso tenemos coincidencias tanto en tabla como en indices.

Estos resultados tienen sentido por como estan sucediendo las cosas. Primero en vez de leer toda la tabla secuencialmente estamos bajando por el arbol hasta encontrar los que nos cumplen la condicion y ya de ahi estamos leyendo en tabla lo que necesitamos (aunque en este caso caché).

2. Mostrar la información de la tupla con estudiante_id igual a 80000.

Esta consulta se hace con el siguiente SQL: SELECT * FROM estudiantes WHERE estudiante_id = 80000; de aquí y las estadisticas podemos ver como lo ha encontrado.

En total se han leido 4 bloques de disco. 3 del indice hash y 1 de la tabla para dar una única tupla resultado.

Esto esta funcionando de la siguiente manera. El SGBD está calculando el hash de 80000 y encuentra esos buckets, de ahí se leen esos 3 bloques y se llega al que nos interesa en la tabla.

3. Mostrar los datos de los estudiantes que tienen un índice entre 100 y 200.

Se han hallado 302000 tuplas y se ha usado esta sentencia: SELECT * FROM estudiantes WHERE indice BETWEEN 100 AND 200; con las estadisticas vemos que se han leido 256 bloques por el arbol de los indices y luego en tabla se han leido otros 336. Todo de disco.

Los numeros cuadran y lo que se hace es llegar al valor minimo bajando por el arbol y luego recorrerlo secuencialmente hasta llegar al valor maximal para obtener todos los punteros que nos llevaran a los bloques que tengan los elementos que cumplen esta condición.

4. Contar el número de estudiantes que tienen una edad de 20 años.

Sabemos que sobre "edad" no tenemos ninguna estructura de busqueda, asi que lo vamos a tener que hacer de manera secuencial. Esta misma teoria es la que nos reflejan las estadisticas. Hemos encontrado 1304000 tuplas y segun estadisticas tenemos 166 bloques leidos de disco y 11 de caché. Dando un total de 177 bloques totales.

Esta es la sentencia usada: SELECT * FROM estudiantes WHERE edad = 20;

El resultado es completamente esperado y no se sale del marco teorico.

5. Mostrar el número total de estudiantes que tienen el mismo índice.

Tenemos 10000 indices coincidentes, para esta consulta se han leido 194000 bloques de disco y 16000 de cache (toda la BD) para poder organizarlos por indice coincidente.

La consulta ha sido esta: SELECT indice, *COUNT*(*) FROM estudiantes GROUP BY indice;
Esto tiene sentido porque para este tenemos que leer si o si todos, y ademas de manera secuencial. Porque aunque tengamos sobre este campo arbol y hash no tiene excesivo sentido usar uno u otro porque el hash seria leerlos secuencialmente pero con los buckets y con el arbol nos pasa lo mismo, es leer el arbol secuencial. Al haber que leerlos todos para hacer las comparaciones lo mas eficaz es hacerlo a lo bruto.

6. Obtener la media de edad de los estudiantes que tienen la misma carrera.

Vamos a ver la consulta SQL y luego ya nos metemos en que pasa. Para este ejercicio sería esta:

SELECT codigo_carrera, *AVG*(edad) FROM estudiantes GROUP BY codigo_carrera;

Por partes, esto hace una media de unos datos, nos interesa como encontramos esos datos que es lo que va a leer bloques, lo otro es matematica. Vemos que tenemos que recorrer todos los bloques de la tabla asi que teoricamente seran los del ejercicio anterior, ademas, antes hemos visto que lo ha hecho de manera secuencial.

Si comprobamos las estadisticas tenemos exactamente eso, que de los 101 codigos de carrera ha ido haciendo las medias (29 años en todas aprox) y que todos los accesos a bloques han sido sequenciales (con los mismos en cache y disco de antes)

7. Insertar un nuevo estudiante con un índice de 100.

En las estadisticas vemos que se accede a 4 bloques en disco y en los indices todos acceden a mas o menos 4 menos el hash por indice que accede a 17 bloques entre caché y memoria.

En general hemos tenido una buena situacion porque no se ha tenido que tocar mucho para almacenar el nuevo registro.
A las malas habria que hacer un split de pagina en los arboles o un desbordamiento de bucket en el hash. Por eso vemos que no se modifica mas que lo que es imprescindible, no hay que rehacer todo.

Para insertar a crazy dave hemos usado esta sentencia:

```
INSERT INTO estudiantes(estudiante_id, nombre, codigo_carrera, edad, indice)
VALUES (30000002, 'Crazy Dave', 7, 30, 100)
```

Cuestión 24. Borrar los índices creados en la cuestión 20. Crear un índice multiclave tipo árbol sobre los campos **código_carrera e índice**. Incluir el código SQL utilizado para ello.

Cuestión 25. Para cada una de las consultas que se muestran a continuación, ¿Qué información se puede obtener de los datos monitorizados por la base de datos al realizar la consulta? Comentar cómo se ha realizado la resolución de la consulta. ¿Cuántos bloques se han leído de cada estructura? ¿Por qué? Importante, reinicializar los datos recolectados de la actividad de la base de datos antes de lanzar cada consulta:

1. Mostrar los estudiantes que tienen un código de carrera de 20 y un índice de 500.

2. Mostrar los estudiantes que tienen un código de carrera de 50 o un índice de 900.

3. Mostrar los estudiantes que tienen un índice de 300.

4. Mostrar los estudiantes que tienen un código de carrera de 80.

Cuestión 26. Crear la tabla **estudiantes3** particionada por el campo **edad** de tal manera que los estudiantes que tengan la misma edad estén juntos en la misma partición. Para cada una de las consultas que se muestran a continuación, ¿Qué información se puede obtener de los datos monitorizados por la base de datos al realizar la consulta? Comentar cómo se ha realizado la resolución de la consulta. ¿Cuántos bloques se han leído de cada estructura? ¿Por qué? Comparar con la teoría. Importante, reinicializar los datos recolectados de la actividad de la base de datos antes de lanzar cada consulta.

1. Mostrar el número de estudiantes con una edad de 25.

2. Mostrar los estudiantes que tienen una edad de 20 o 25 o 30 años.

3. Mostrar los estudiantes que tienen una edad entre 25 y 30 años (incluidos).

4. Mostrar los estudiantes que tienen una edad mayor de 50 años.

Cuestión 27. A la vista de los resultados obtenidos de este apartado, comentar las conclusiones que se pueden obtener del acceso de PostgreSQL a los datos almacenados en disco.

Bibliografía (PostgreSQL 18.1)

- Capítulo 1: Getting Started.
- Capítulo 5: 5.6 System Columns.
- Capítulo 5: 5.12 Table Partitioning.
- Capítulo 11: Indexes.
- Capítulo 19: Server Configuration.
- Capítulo 24: Routine Database Maintenance Tasks.
- Capítulo 27: Monitoring Database Activity. The statistics Collector
- Capítulo 27.6: Monitoring Disk Usage. Determining Disk Usage
- Capítulo 52: System Catalogs
- Capítulo 65.1: B-Tree Indexes
- Capítulo 65.6: Hash Indexes
- Capítulo 67: Database Physical Storage
- Capítulo VI.II: PostgresSQL Client Applications.
- Capítulo VI.III: PostgresSQL Server Applications.
- Apéndice F: Additional Supplied Modules. Pageinspect, pgstatutuple
- Apéndice G: Additional Supplied Programs. Oid2name